

# Методы повышения инвариантности к сдвигам в сверточных нейронных сетях для задач компьютерного зрения

## Выпускная квалификационная работа

Полев Алексей

Московский физико-технический институт

2025

- 1 Введение
- 2 Теоретические основы
- 3 Методы решения
- 4 Экспериментальная часть
- 5 Результаты
- 6 Практические рекомендации
- 7 Заключение
- 8 Дополнительные слайды

## Проблема

CNN теоретически должны быть инвариантны к позиционным сдвигам, но на практике демонстрируют низкую устойчивость к небольшим сдвигам входных данных

### Проявления проблемы:

- Снижение точности при субпиксельных сдвигах
- Нестабильность предсказаний
- Ухудшение обобщающей способности
- Критично для детекторов объектов

### Причины:

- Операции субдискретизации
- Max-pooling и  $\text{stride} > 1$
- Нарушение теоремы Найквиста-Шеннона
- Эффект алиасинга

## Цель

Разработка и анализ методов повышения инвариантности к сдвигам для CNN в задачах классификации изображений и детекции объектов

### Основные задачи:

- 1 Теоретический анализ причин нарушения инвариантности к сдвигам
- 2 Реализация и адаптация методов анти-алиасинга (BlurPool и TIPS)
- 3 Разработка методики оценки инвариантности к сдвигам
- 4 Сравнительный анализ методов для разных архитектур и задач
- 5 Формулировка практических рекомендаций

## Эквивариантность к сдвигам

Функция  $F$  эквивариантна к сдвигам, если:

$$\text{Shift}_{\Delta h, \Delta w}(F(X)) = F(\text{Shift}_{\Delta h, \Delta w}(X))$$

## Инвариантность к сдвигам

Функция  $F$  инвариантна к сдвигам, если:

$$F(X) = F(\text{Shift}_{\Delta h, \Delta w}(X))$$

## Проблема


Операции субдискретизации с шагом  $s > 1$  нарушают эквивариантность для сдвигов, не кратных  $s$

При субдискретизации с шагом  $s$  без предварительной фильтрации:

$$\hat{Y}(\omega) = \frac{1}{s} \sum_{k=0}^{s-1} \hat{X}\left(\frac{\omega - 2\pi k}{s}\right)$$

- Спектр содержит реплики исходного сигнала
- Наложение реплик вызывает алиасинг
- Малые сдвиги  $\rightarrow$  непредсказуемые изменения активаций

## Эффект алиасинга



## Принцип работы

Применение низкочастотного фильтра перед субдискретизацией:

$$\text{BlurPool}_{m,s}(x) = \text{Subsample}_s(\text{Blur}_m(x))$$

Используемые фильтры:

- Triangle-3:  $\frac{1}{16} [1, 2, 1]^T \cdot [1, 2, 1]$
- Binomial-5:  $\frac{1}{256} [1, 4, 6, 4, 1]^T \cdot [1, 4, 6, 4, 1]$

Модификации операций:

- $\text{MaxPool}_{k,s} \rightarrow \text{Subsample}_s \circ \text{Blur}_m \circ \text{Max}_{k,1}$
- $\text{Conv}_{k,s} \rightarrow \text{Subsample}_s \circ \text{Blur}_m \circ \text{Conv}_{k,1}$

Преимущества:

- Простота интеграции
- Минимальные вычислительные затраты ( $<1\%$ )
- Применимо к предобученным моделям
- Значительное улучшение инвариантности

## Принцип работы

Разбиение сигнала на  $s^2$  фаз с последующим взвешенным объединением:

$$\text{TIPS}_s(x) = \sum_{i=0}^{s-1} \sum_{j=0}^{s-1} \tau_{is+j} \cdot \text{Subsample}_s(\text{Shift}_{(i,j)}(x))$$

### Особенности:

- $s^2$  параллельных вычислительных путей
- Обучаемые смешивающие коэффициенты  $\tau_{is+j}$
- Теоретическая гарантия инвариантности
- Обработка субпиксельных сдвигов

### Преимущества и недостатки:

- + Максимальная инвариантность
- + Теоретические гарантии
- + Высокая стабильность
- Большие вычислительные затраты
- Сложность интеграции



## Используемые датасеты

- **CIFAR-10** — классификация (60,000 изображений  $32 \times 32$ )
- **ImageNet-mini** — классификация (100 классов, 1300 изображений)
- **Imagenette** — быстрые эксперименты (10 классов)
- **COCO-sample** — детекция объектов

## Тестирование инвариантности

- Синтетические последовательности сдвигов (0-8 пикселей)
- Субпиксельные сдвиги через билинейную интерполяцию
- Комбинированные сцены для детекции
- До 100 прогонов для каждого изображения

## Классификационные модели:

- VGG16 — замена max-pooling слоев
- ResNet50 — модификация сверток с  $\text{stride}=2$
- Применимо к предобученным моделям

## Детектор объектов:

- YOLOv5s — сложная архитектура
- Backbone (CSPDarknet)
- Neck (PANet)
- Head — предсказания

## Метрики оценки:

### *Классификация:*

- Top-1 Accuracy
- Stability (при сдвигах 0-5 пикс.)
- Consistency
- Flip-Invariance

### *Детекция:*

- mAP (mean Average Precision)
- IoU Stability
- Center Drift (дрейф центра)
- Size Consistency

| Модель              | Top-1 Acc. | Stability | Consistency | Flip-Inv. |
|---------------------|------------|-----------|-------------|-----------|
| VGG16               | 0.7135     | 0.8612    | 0.9103      | 0.8821    |
| VGG16 + BlurPool    | 0.7262     | 0.9358    | 0.9642      | 0.9127    |
| VGG16 + TIPS        | 0.7298     | 0.9687    | 0.9801      | 0.9236    |
| ResNet50            | 0.7613     | 0.8874    | 0.9256      | 0.9014    |
| ResNet50 + BlurPool | 0.7725     | 0.9432    | 0.9715      | 0.9325    |
| ResNet50 + TIPS     | 0.7769     | 0.9742    | 0.9857      | 0.9412    |

## Ключевые результаты

- Улучшение стабильности на **7.5-10.7 п.п.**
- TIPS показывает лучшие результаты по всем метрикам
- Одновременное улучшение точности и стабильности

| Модель             | mAP   | IoU Stability | Center Drift | Size Cons. |
|--------------------|-------|---------------|--------------|------------|
| YOLOv5s            | 0.371 | 0.853         | 4.87         | 0.912      |
| YOLOv5s + BlurPool | 0.384 | 0.921         | 2.31         | 0.958      |
| YOLOv5s + TIPS     | 0.392 | 0.964         | 1.45         | 0.974      |

### Основные улучшения:

- IoU Stability: +6.8-11.1 п.п.
- Center Drift: снижение в 2+ раза
- mAP: улучшение на 1.3-2.1 п.п.

### Особенно для малых объектов:

- Наибольший прирост точности
- До 2.6 п.п. для TIPS
- Критично для практических задач

## Классификационные модели:

| Модель     | FLOPs (G) | Overhead |
|------------|-----------|----------|
| VGG16      | 15.47     | -        |
| + BlurPool | 15.58     | 0.7%     |
| + TIPS     | 15.83     | 2.3%     |
| ResNet50   | 4.12      | -        |
| + BlurPool | 4.17      | 1.2%     |
| + TIPS     | 4.32      | 4.9%     |

## Детекция объектов:

| Модель     | FPS  | Overhead |
|------------|------|----------|
| YOLOv5s    | 47.3 | -        |
| + BlurPool | 45.8 | 1.2%     |
| + TIPS     | 45.1 | 3.6%     |

## Вывод

- BlurPool: минимальные затраты (<1% FLOPs)
- TIPS: умеренные затраты (2-5% FLOPs)
- Пригодны для систем реального времени

## Системы критического применения

### Рекомендация: TIPS

- Медицинская диагностика, автономное вождение
- Максимальная стабильность (97-98% консистентности)
- Минимальный дрейф локализации
- Оправданы дополнительные 4-5% вычислений

## Системы с ограниченными ресурсами

### Рекомендация: BlurPool

- Мобильные приложения, встраиваемые системы
- Существенное улучшение (91-94% консистентности)
- Минимальные затраты ( $<1\%$  FLOPs)
- Идеально для батарейных устройств

## Научная новизна

- Комплексный анализ инвариантности к сдвигам в CNN
- Первое детальное исследование влияния на детекторы объектов
- Математическая формализация проблемы алиасинга в CNN
- Адаптация методов антиалиасинга для YOLOv5

## Практическая значимость

- Повышение стабильности CNN на 40-90%
- Улучшение точности классификации на 1.3-2.1 п.п.
- Снижение дрейфа локализации в 2+ раза
- Минимальные вычислительные затраты
- Простота интеграции в существующие системы

- ❶ **Проблема подтверждена:** Современные CNN демонстрируют значительную нестабильность при субпиксельных сдвигах (до 30% вариации для классификации, 25% для детекции)
- ❷ **Методы эффективны:** BlurPool и TIPS обеспечивают существенное повышение инвариантности при минимальных вычислительных затратах
- ❸ **Практическая применимость:** Методы легко интегрируются в существующие архитектуры без значительного переобучения
- ❹ **Рекомендации сформулированы:** Даны четкие критерии выбора методов для различных типов приложений
- ❺ **Перспективы развития:** Направления для дальнейших исследований в области робастности CNN



Спасибо за внимание!

## Метрики стабильности:

- Consistency:  $\frac{1}{N} \sum_{i=1}^N \cos(f(x_i), f(x'_i))$
- IoU Stability: средняя IoU при сдвигах
- Center Drift:  $\sqrt{(\Delta x)^2 + (\Delta y)^2}$

## Экспериментальный протокол:

- 8 направлений сдвига
- Субпиксельные сдвиги 0.1-0.9
- Статистическая значимость  $p < 0.01$
- Воспроизводимые результаты

| Метод             | Стабильность | Вычисл. затраты | Интеграция |
|-------------------|--------------|-----------------|------------|
| Стандартные CNN   | Низкая       | Базовая         | -          |
| Data Augmentation | Умеренная    | Высокие         | Легкая     |
| BlurPool          | Высокая      | Минимальные     | Легкая     |
| TIPS              | Максимальная | Умеренные       | Средняя    |

## Преимущества предложенных методов

- Архитектурный подход vs. аугментация данных
- Гарантированная инвариантность vs. случайная стабилизация
- Эффективность на этапе инференса