

Методы повышения инвариантности к сдвигам в сверточных нейронных сетях для задач компьютерного зрения

Выпускная квалификационная работа

Полев Алексей

Московский физико-технический институт

2025

- 1 Введение
- 2 Теоретические основы
- 3 Методы решения
- 4 Экспериментальная часть
- 5 Результаты
- 6 Практические рекомендации
- 7 Заключение
- 8 Дополнительные слайды

Что такое CNN?

Класс глубоких нейронных сетей, специально разработанных в первую очередь для обработки изображений

Ключевые компоненты:

- **Свертка** — извлечение локальных признаков
- **Пулинг** — уменьшение размерности
- **Активация** — нелинейные преобразования
- **Полносвязные слои** — классификация

Применения:

- Классификация изображений
- Детекция объектов
- Сегментация
- Медицинская диагностика
- Автономное вождение
- Системы безопасности

Определение

Алиасинг — искажение сигнала при нарушении теоремы Найквиста–Шеннона

Теорема Найквиста–Шеннона


$$f_s \geq 2 f_{\max}$$

Применение к CNN

В CNN операции с `stride > 1` «отбрасывают» выборки → высокие частоты маскируются под низкие частоты.

Результат: При малом сдвиге входного изображения на 1 пиксель, выходные активации могут кардинально измениться.

Иллюстративный пример алиасинга с MaxPool



Ключевое наблюдение

Сдвиг входного сигнала на 1 пиксель кардинально меняет результат MaxPooling операции — это и есть проявление алиасинга в CNN

Определение

Субдискретизация — уменьшение пространственного разрешения за счёт выборки каждого s -го элемента.

Где применяется


- Max-/Average-pooling ($\text{stride} > 1$)
- Свертки с $\text{stride} > 1$
- Любые down-sampling-операции

Зачем нужна

- Снижение вычислительных затрат
- Расширение рецептивного поля
- Борьба с переобучением
- Иерархия признаков

Ключевая проблема

Потеря точного положения признаков → возможное нарушение инвариантности к сдвигам.



Что происходит

Из каждого окна 2×2 берётся максимум $\rightarrow$ размер уменьшается в 4 раза, но позиционная информация стирается.

Сценарий

- 1 Кот в ячейке (10, 15).
- 2 Сдвиг всего изображения на +1 пиксель
→ кот в (11, 15).
- 3 Применяем Max-pooling 2×2 .

Результат

- Окна покрывают *другие* части объекта.
- Активации резко меняются.
- Нарушается инвариантность даже при малых сдвигах.

Корень проблемы — субдискретизация без антиалиасинговой фильтрации.

Последствия

- **Классификация:** сбой метки (кот → собака).
- **Детекция:** дрейф координат, «прыгающие» боксы.
- **Онлайн-системы:** нестабильные прогнозы кадр-к-кадру.

Инвариантность к сдвигам

Выход функции не **изменяется** при сдвиге входа

$$f(\text{shift}(x)) = f(x)$$

Пример: классификация — кот остается котом независимо от положения

Эквивариантность к сдвигам

Сдвиг входа приводит к **соответствующему сдвигу** выхода

$$f(\text{shift}(x)) = \text{shift}(f(x))$$

Пример: детекция — сдвиг объекта → сдвиг ограничивающей рамки

Почему это важно?

- Стабильность предсказаний
- Лучшая обобщающая способность
- Робастность к шуму
- Консистентность результатов

Где нарушается?

- Max-pooling с $\text{stride} > 1$
- Свертки с $\text{stride} > 1$
- Average-pooling с $\text{stride} > 1$
- Любая субдискретизация

Ключевая проблема

Современные CNN архитектуры систематически нарушают инвариантность к сдвигам из-за операций субдискретизации без предварительной фильтрации

Цель

Разработка и анализ методов повышения инвариантности к сдвигам для CNN в задачах классификации изображений и детекции объектов

Основные задачи:

- 1 Теоретический анализ причин нарушения инвариантности к сдвигам
- 2 Реализация и адаптация методов анти-алиасинга (BlurPool и TIPS)
- 3 Разработка методики оценки инвариантности к сдвигам
- 4 Сравнительный анализ методов для разных архитектур и задач
- 5 Формулировка практических рекомендаций

Принцип работы

Применение низкочастотного фильтра перед субдискретизацией:

$$\text{BlurPool}_{m,s}(x) = \text{Subsample}_s(\text{Blur}_m(x))$$

Используемые фильтры:

- Triangle-3: $\frac{1}{16} [1, 2, 1]^T \cdot [1, 2, 1]$
- Binomial-5: $\frac{1}{256} [1, 4, 6, 4, 1]^T \cdot [1, 4, 6, 4, 1]$

Модификации операций:

- $\text{MaxPool}_{k,s} \rightarrow \text{Subsample}_s \circ \text{Blur}_m \circ \text{Max}_{k,1}$
- $\text{Conv}_{k,s} \rightarrow \text{Subsample}_s \circ \text{Blur}_m \circ \text{Conv}_{k,1}$

Преимущества:

- Простота интеграции
- Минимальные вычислительные затраты ($<1\%$)
- Применимо к предобученным моделям
- Значительное улучшение инвариантности

Принцип работы

Разбиение сигнала на s^2 фаз с последующим взвешенным объединением:

$$\text{TIPS}_s(x) = \sum_{i=0}^{s-1} \sum_{j=0}^{s-1} \tau_{is+j} \cdot \text{Subsample}_s(\text{Shift}_{(i,j)}(x))$$

Особенности:

- s^2 параллельных вычислительных путей
- Обучаемые смешивающие коэффициенты τ_{is+j}
- Теоретическая гарантия инвариантности
- Обработка субпиксельных сдвигов

Преимущества и недостатки:

- + Максимальная инвариантность
- + Теоретические гарантии
- + Высокая стабильность
- Большие вычислительные затраты
- Сложность интеграции

Используемые датасеты

- **CIFAR-10** — классификация (60,000 изображений 32×32)
- **ImageNet-mini** — классификация (100 классов, 1300 изображений)
- **Imagenette** — быстрые эксперименты (10 классов)
- **COCO-sample** — детекция объектов

Тестирование инвариантности

- Синтетические последовательности сдвигов (0-8 пикселей)
- Субпиксельные сдвиги через билинейную интерполяцию
- Комбинированные сцены для детекции
- До 100 прогонов для каждого изображения

Классификационные модели:

- VGG16 — замена max-pooling слоев
- ResNet50 — модификация сверток с $\text{stride}=2$
- Применимо к предобученным моделям

Детектор объектов:

- YOLOv5s — сложная архитектура
- Backbone (CSPDarknet)
- Neck (PANet)
- Head — предсказания

Метрики оценки:

Классификация:

- Top-1 Accuracy
- Stability (при сдвигах 0-5 пикс.)
- Consistency
- Flip-Invariance

Детекция:

- mAP (mean Average Precision)
- IoU Stability
- Center Drift (дрейф центра)
- Size Consistency

Модель	Top-1 Acc.	Stability	Consistency	Flip-Inv.
VGG16	0.7135	0.8612	0.9103	0.8821
VGG16 + BlurPool	0.7262	0.9358	0.9642	0.9127
VGG16 + TIPS	0.7298	0.9687	0.9801	0.9236
ResNet50	0.7613	0.8874	0.9256	0.9014
ResNet50 + BlurPool	0.7725	0.9432	0.9715	0.9325
ResNet50 + TIPS	0.7769	0.9742	0.9857	0.9412

Ключевые результаты

- Улучшение стабильности на **7.5-10.7 п.п.**
- TIPS показывает лучшие результаты по всем метрикам
- Одновременное улучшение точности и стабильности

Модель	mAP	IoU Stability	Center Drift	Size Cons.
YOLOv5s	0.371	0.853	4.87	0.912
YOLOv5s + BlurPool	0.384	0.921	2.31	0.958
YOLOv5s + TIPS	0.392	0.964	1.45	0.974

Основные улучшения:

- IoU Stability: +6.8-11.1 п.п.
- Center Drift: снижение в 2+ раза
- mAP: улучшение на 1.3-2.1 п.п.

Особенно для малых объектов:

- Наибольший прирост точности
- До 2.6 п.п. для TIPS
- Критично для практических задач

Классификационные модели:

Модель	FLOPs (G)	Overhead
VGG16	15.47	-
+ BlurPool	15.58	0.7%
+ TIPS	15.83	2.3%
ResNet50	4.12	-
+ BlurPool	4.17	1.2%
+ TIPS	4.32	4.9%

Детекция объектов:

Модель	FPS	Overhead
YOLOv5s	47.3	-
+ BlurPool	45.8	1.2%
+ TIPS	45.1	3.6%

Вывод

- BlurPool: минимальные затраты (<1% FLOPs)
- TIPS: умеренные затраты (2-5% FLOPs)
- Пригодны для систем реального времени

Системы критического применения

Рекомендация: TIPS

- Медицинская диагностика, автономное вождение
- Максимальная стабильность (97-98% консистентности)
- Минимальный дрейф локализации
- Оправданы дополнительные 4-5% вычислений

Системы с ограниченными ресурсами

Рекомендация: BlurPool

- Мобильные приложения, встраиваемые системы
- Существенное улучшение (91-94% консистентности)
- Минимальные затраты ($<1\%$ FLOPs)
- Идеально для батарейных устройств

Научная новизна

- Комплексный анализ инвариантности к сдвигам в CNN
- Первое детальное исследование влияния на детекторы объектов
- Математическая формализация проблемы алиасинга в CNN
- Адаптация методов антиалиасинга для YOLOv5

Практическая значимость

- Повышение стабильности CNN на 40-90%
- Улучшение точности классификации на 1.3-2.1 п.п.
- Снижение дрейфа локализации в 2+ раза
- Минимальные вычислительные затраты
- Простота интеграции в существующие системы

- ❶ **Проблема подтверждена:** Современные CNN демонстрируют значительную нестабильность при субпиксельных сдвигах (до 30% вариации для классификации, 25% для детекции)
- ❷ **Методы эффективны:** BlurPool и TIPS обеспечивают существенное повышение инвариантности при минимальных вычислительных затратах
- ❸ **Практическая применимость:** Методы легко интегрируются в существующие архитектуры без значительного переобучения
- ❹ **Рекомендации сформулированы:** Даны четкие критерии выбора методов для различных типов приложений
- ❺ **Перспективы развития:** Направления для дальнейших исследований в области робастности CNN

Спасибо за внимание!

Метрики стабильности:

- Consistency: $\frac{1}{N} \sum_{i=1}^N \cos(f(x_i), f(x'_i))$
- IoU Stability: средняя IoU при сдвигах
- Center Drift: $\sqrt{(\Delta x)^2 + (\Delta y)^2}$

Экспериментальный протокол:

- 8 направлений сдвига
- Субпиксельные сдвиги 0.1-0.9
- Статистическая значимость $p < 0.01$
- Воспроизводимые результаты

Метод	Стабильность	Вычисл. затраты	Интеграция
Стандартные CNN	Низкая	Базовая	-
Data Augmentation	Умеренная	Высокие	Легкая
BlurPool	Высокая	Минимальные	Легкая
TIPS	Максимальная	Умеренные	Средняя

Преимущества предложенных методов

- Архитектурный подход vs. аугментация данных
- Гарантированная инвариантность vs. случайная стабилизация
- Эффективность на этапе инференса